

Meta-Harness: 模型 Harness 的端到端优化

Meta-Harness: End-to-End Optimization of Model Harnesses

Yoonho Lee (Stanford) 等

导读整理: AI Assistant

arXiv:2603.28052

Abstract

大语言模型 (LLM) 系统的性能不仅取决于模型权重, 还取决于其 *harness* (控制信息的存储、检索和呈现的代码)。然而, *harness* 仍主要由手工设计, 现有的文本优化器由于过度压缩反馈而不适用于此场景。本文介绍 **Meta-Harness**, 这是一个外环系统, 通过端到端搜索来优化 LLM 应用的 *harness* 代码。它使用一个智能体 proposer, 通过文件系统访问所有先验候选的源代码、分数和执行轨迹。在线文本分类任务上, Meta-Harness 超越最先进的上下文管理系统 7.7 个百分点, 同时使用少 4 倍的上下文 token。在检索增强的数学推理上, 单个发现的 *harness* 在 200 个 IMO 级别问题上平均提升 4.7 个百分点。在智能体编码任务上, 发现的 *harness* 超越了最佳手工设计的基线。

Contents

1	论文总览	2
1.1	研究背景	2
1.2	现有方法的局限	2
1.3	主要贡献	2
2	核心方法	2
2.1	问题定义	2
2.2	Meta-Harness 搜索循环	3
2.3	代码空间搜索的优势	3
3	实验分析	3
3.1	在线文本分类	3
3.2	检索增强数学推理	4
3.3	TerminalBench-2 智能体编码	4
4	关键洞察	5
5	实践建议	5
6	局限与未来方向	5
7	总结	5

1 论文总览

1.1 研究背景

Harness 的重要性：改变固定大语言模型周围的 harness 可以在同一基准测试上产生 6 倍的性能差距。Harness 是决定存储什么、检索什么以及向模型展示什么的代码，它通常与模型本身一样重要。

当前问题：尽管 harness 工程很重要，但它仍然是手工的：从业者检查失败案例、调整启发式方法，并在少量设计上进行迭代。本文探索这一过程是否可以自动化。

1.2 现有方法的局限

现有的文本优化方法对 harness 工程不匹配，因为它们通常使用短视或严重压缩的反馈：

- 仅依赖当前候选或标量分数
- 将反馈限制为简短模板或 LLM 生成的摘要
- 每个优化步骤的上下文范围仅为 100 到 30,000 token

Harness 作用于长视程：关于存储什么、何时检索或如何呈现的单一选择可能会影响许多推理步骤后的行为。压缩的反馈往往会移除追踪下游失败到早期 harness 决策所需的信息。

1.3 主要贡献

1. 提出 **Meta-Harness**：一个通过端到端搜索优化 harness 的外环系统，使用智能体 proposer 通过文件系统访问完整的先验经验历史
2. 文件系统接口：存储所有先验候选的源代码、执行轨迹和分数，proposer 可以通过标准操作（如 grep 和 cat）选择性检索
3. 三大任务验证：
 - 在线文本分类：超越 ACE 7.7 个百分点，使用少 4 倍上下文 token
 - 检索增强数学推理：在 200 个 IMO 级别问题上平均提升 4.7 个百分点
 - 智能体编码（TerminalBench-2）：超越所有手工设计的 Haiku 4.5 智能体

2 核心方法

2.1 问题定义

Harness 是一个有状态程序，它包装语言模型并决定模型在每个步骤看到什么上下文。形式化地，令 M 表示固定语言模型， $\mathcal{X}$ 表示任务分布。对于 harness H 和任务实例 $x \sim \mathcal{X}$ ，执行 rollout 轨迹 $\tau \sim p_M(H, x)$ 。目标是：

$$H^* = \arg \max_H \mathbb{E}_{x \sim \mathcal{X}, \tau \sim p_M(H, x)} r(\tau, x)$$

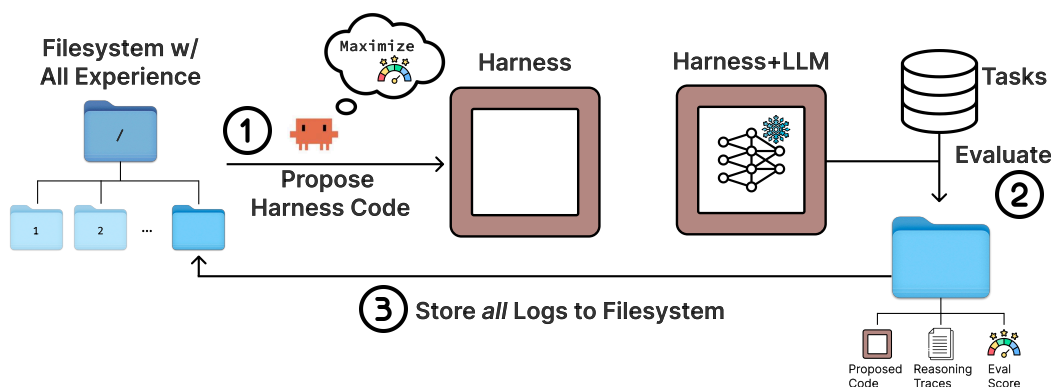


Figure 1: Meta-Harness 搜索循环。(1) 智能体读取包含所有先验候选源代码、执行轨迹和分数的文件系统，并提出新的 harness；(2) 在评估任务上评估提出的 harness；(3) 所有日志（提出的代码、推理轨迹、评估分数）存储在新目录中，循环重复

2.2 Meta-Harness 搜索循环

关键设计：

1. **Coding Agent Proposer**: 基于语言模型的系统，可以调用开发工具并修改代码
2. 完整历史暴露：通过文件系统存储所有先验 harness 的源代码、分数和执行轨迹
3. 选择性检索：proposer 通过终端工具（grep、cat）查询文件系统，而非作为单一提示摄入
4. 最小结构约束：不依赖父代选择规则或预设搜索启发式，proposer 自由检查任何先验 harness

2.3 代码空间搜索的优势

- 因果推理：通过检查执行轨迹，proposer 可以推断 harness 为什么失败，以及哪些早期设计决策可能导致失败
- 算法级修改：proposer 可以修改检索、记忆或提示构造逻辑的算法结构，而非填充模板
- 自然正则化：将 harness 表示为程序提供自然正则化偏置，编码模型倾向于提出连贯的算法而非脆弱的硬编码解

3 实验分析

3.1 在线文本分类

设置：使用 GPT-OSS-120B 作为 LLM 分类器，三个数据集（LawBench、Symptom2Disease、USPTO-50k），20 次迭代产生 40 个候选 harness。

对比方法：

- 文本优化器：OpenEvolve（进化搜索）、TTT-Discover（PUCT 规则）
- 手工 harness：ACE（代理上下文工程）、MCE（元上下文工程）

Table 1: 在线文本分类主要结果

方法	准确率 (%)	上下文 token (K)
Zero-shot	32.1	0.1
Few-shot (32)	38.9	12.5
ACE	40.9	50.8
MCE	40.0	28.5
Meta-Harness	48.6	11.4

关键结果:

核心发现:

- Meta-Harness 在 10 倍更少评估下匹配最佳文本优化器，最终准确率高 10 个百分点
- 超越 ACE 7.7 个百分点，同时使用少 4 倍上下文 token
- 在 9 个 OOD 数据集上，6 个取得最佳性能

3.2 检索增强数学推理

设置：检索 corpus 包含 $\geq 500,000$ 个已解决问题，在 250 个奥林匹克难度问题上优化 40 次迭代，在 200 个 IMO 级别问题上评估。

关键结果:

Table 2: 数学推理结果（平均准确率%）

方法	平均准确率
无检索	基准
稠密检索	+0.2
随机 few-shot	+0.5
BM25 检索	+3.4
Meta-Harness	+4.7

核心发现：单个发现的 harness 在 5 个未见过的模型上泛化，平均提升 4.7 个百分点。

3.3 TerminalBench-2 智能体编码

设置：89 个挑战性任务，需要长视程、完全自主执行。

关键结果:

- **Opus 4.6**: 76.4% 通过率，超越 Terminus-KIRA (74.7%)，在所有 Opus 4.5 智能体中排名第 2
- **Haiku 4.5**: 37.6% 通过率，超越次佳 Goose (35.5%) 2.1 个百分点，排名第 1

4 关键洞察

核心洞察

1. 完整经验历史的价值：文件系统接口使 proposer 能够选择性诊断原始代码和执行轨迹，而非从压缩摘要优化。消融实验证明，仅有分数或分数 + 摘要的条件远逊于完整执行轨迹访问。
2. 最小结构偏置：Meta-Harness 不依赖父代选择规则或预设搜索启发式，这使得它可以自动随 coding agent 能力提升而改进。
3. 代码空间搜索的可解释性：过拟合在代码空间更易检查：脆弱的 if 链或硬编码类映射可通过检查发现，而权重空间的过拟合则不然。
4. 长视程依赖的关键性：Harness 工程需要在代码、分数和执行轨迹中分布式的环境反馈，这难以预先总结。

5 实践建议

建议：对于希望应用类似方法的从业者：

1. 建立文件系统接口：存储所有候选的源代码、执行日志和评估分数，确保 proposer 可以通过命令行工具访问。
2. 选择强大的 **coding agent**：Meta-Harness 使用 Claude Code (Opus-4.6)，coding agent 的能力直接影响搜索质量。
3. 最小化外环结构：避免硬编码搜索启发式，让 proposer 自主决定检查什么、诊断什么以及如何修改。
4. 关注可解释性：定期检查 proposer 的搜索轨迹，理解它如何形成因果假设并修订 harness。
5. **Pareto** 前沿优化：同时考虑准确性和上下文成本等多目标，让 proposer 根据期望权衡发现 harness。

6 局限与未来方向

- **Proposer** 依赖：实验仅使用一个强大的 coding agent (Claude Code)，跨不同 proposer 的泛化性有待研究
- 领域覆盖：仅在三个领域验证，可能在其他领域的效果不同
- 未来方向：协同进化 harness 和模型权重，让策略塑造模型学习内容，反之亦然

7 总结

核心观点：Meta-Harness 通过端到端搜索和完整经验历史访问，实现了 harness 工程的自动化。关键创新在于将诊断和提案委托给 coding agent，通过文件系统接口暴露完整

历史，使 proposer 能够形成因果假设并针对性修改。实验证明该方法在文本分类、数学推理和智能体编码三个领域均超越手工设计的最佳 harness。

核心引用

- 论文: Meta-Harness: End-to-End Optimization of Model Harnesses
- 作者: Yoonho Lee, Roshen Nair, Qizheng Zhang, Kangwook Lee, Omar Khattab, Chelsea Finn
- 机构: Stanford, KRAFTON, MIT
- arXiv: 2603.28052
- 项目页面: <https://yoonholee.com/meta-harness/>